

INSTITUIÇÃO: UNIPÊ

DISCIPLINA: TÓPICOS AVANÇADOS - Recuperação de Informação / PLN

ATIVIDADE: Laboratório Prático 04 - Desafio Integrador

PROFESSOR: Me. Ricardo Roberto de Lima

PÚBLICO-ALVO: Grupos de 2 a 3 alunos – valor: 0.5 pontos extras na AV1.

Título do Desafio: AgroSearch - Motor de Busca Inteligente

1. Estudo de Caso (Contexto)

A startup AgroTech Solutions possui uma base interna com dezenas de manuais técnicos sobre agricultura sustentável, controle de pragas e irrigação. Atualmente, os técnicos de campo perdem muito tempo procurando informações específicas. A diretoria contratou sua equipe para desenvolver o AgroSearch, um prototype de motor de busca textual. O sistema deve permitir que o técnico digite uma consulta e o sistema retorne os trechos mais relevantes, ranqueados por relevância.

2. Objetivos de Aprendizagem

- Consolidar o pipeline de pré-processamento de texto (Tokenização, Normalização, Stopwords, Stemming).
- Compreender a construção e a utilidade do Índice Invertido em memória.
- Aplicar a métrica TF-IDF para ranqueamento de documentos.
- Desenvolver uma interface interativa e unificada utilizando Streamlit.

3. Regras e Entregáveis

- Equipes: Grupos de 2 ou 3 alunos.
- Entrega: Um único arquivo .py (Streamlit) e um breve relatório em PDF (máx. 2 páginas).
- Restrição Técnica: **É PROIBIDO o uso de bibliotecas de alto nível (ex: scikit-learn, TfidfVectorizer). O índice invertido e o cálculo do TF-IDF devem ser implementados 'do zero' (from scratch).**

4. Especificações Técnicas

A aplicação Streamlit deve integrar os 3 pilares:

Fase 1: O Pipeline de Pré-processamento

Implementar as 4 etapas. A UI deve permitir ligar/desligar Stemming e Stopwords via checkboxes para ver o vocabulário mudar dinamicamente.

Fase 2: O Índice Invertido

Construir o Índice Invertido (Termo -> [IDs de Docs]) usando os tokens pré-processados. Exibir via st.json ou st.dataframe.

Fase 3: Busca e Ranqueamento TF-IDF

O usuário digita uma Query. O sistema calcula TF, IDF e TF-IDF. Exibir uma tabela ordenada do maior para o menor TF-IDF acumulado, destacando o documento vencedor.

5. Base de Documentos (Hardcode sugerido)

1. Doc 1: A soja requer irrigação constante durante o período de floração para garantir a produtividade.
2. Doc 2: O controle biológico de lagartas na soja pode ser feito com a vespa Trichogramma.
3. Doc 3: A adubação verde com leguminosas melhora o nitrogênio no solo para o milho.
4. Doc 4: Lagartas desfolhadoras causam grande prejuízo na cultura da soja e do algodão.
5. Doc 5: A irrigação por gotejamento economiza água e é ideal para o cultivo orgânico.

6. Critérios de Avaliação

Critério	Peso	Descrição
Correção do Pipeline	20%	Pré-processamento remove acentos, lowercases e aplica stemming/stopwords.
Índice Invertido	20%	Estrutura reflete corretamente a relação Termo-Documento com tokens limpos.
Cálculo TF-IDF	30%	Fórmulas de TF, IDF e ranqueamento final estão matematicamente corretos.
Interface (Streamlit)	20%	UI intuitiva, permite interação e exibe dados de forma clara.
Trabalho em Equipe	10%	Divisão clara de tarefas no relatório e qualidade do código.

7. Desafio Bônus (Nota Extra)

Implementar a Similaridade de Cosseno entre o vetor da Query e o vetor TF-IDF dos documentos para lidar melhor com consultas de múltiplas palavras.