

AgroSearch: Motor de Busca Inteligente

Índice Invertido + TF-IDF (from scratch) + Similaridade de Cosseno
Relatório Técnico do Desafio Integrador, UNIPÊ, Centro Universitário de João Pessoa
Disciplina: Tendências em Ciência da Computação
Professor: Me. Ricardo Roberto de Lima
Autor: Pedro Nícollas Pereira Leon Lopes

1. Contexto e Problema

A AgroTech Solutions possui uma base interna com dezenas de manuais técnicos sobre agricultura sustentável, controle de pragas e irrigação, mas os técnicos de campo perdem tempo procurando trechos específicos em meio a esse volume de texto. O AgroSearch é um protótipo de motor de busca textual que recebe uma consulta e devolve os documentos mais relevantes, ranqueados por pontuação. Por restrição do enunciado, o núcleo do sistema (pipeline de pré-processamento, índice invertido e cálculo de TF-IDF) foi implementado inteiramente do zero, sem bibliotecas de alto nível como scikit-learn ou TfidfVectorizer, o que exigiu atenção redobrada à corretude matemática das fórmulas de TF, IDF e similaridade de cosseno.

2. Arquitetura da Solução

A aplicação é modular: o corpus vive em data/corpus_agricola.json e as funções de pré-processamento, indexação e ranqueamento ficam separadas da interface. O fluxo tem três fases em abas, mais um bônus.

Fase	Componente	Implementação
1	Pipeline de pré-processamento	Tokenização por regex, normalização para minúsculas com remoção de acentos (NFD -> ASCII), remoção de stopwords em português (lista curada local) e stemming rudimentar por corte de sufixos comuns (ex.: "-ção", "-mente", "-ados"). Stopwords e stemming são ligados/desligados por checkbox, recalculando o vocabulário em tempo real.
2	Índice Invertido	Dicionário Termo -> [IDs de Documentos] construído em memória a partir dos tokens já pré-processados de cada documento, exibido em tabela (com DF de cada termo) ou em JSON.
3	Busca e Ranqueamento TF-IDF	$TF(t,d) = \text{ocorrências de } t \text{ em } d / \text{total de termos em } d$. $IDF(t) = \log(N / DF(t))$. Para cada documento, soma-se o TF-IDF de todos os termos da consulta ("TF-IDF acumulado"), gerando uma tabela ordenada da maior para a menor pontuação, com destaque visual do documento vencedor.
Bônus	Similaridade de Cosseno	Vetores TF-IDF completos (dimensão = tamanho do vocabulário) para a query e para cada documento. $\cos = (q \cdot d) / (q * d)$, calculado com produto escalar e normas em Python puro (sem numpy/sklearn), lidando melhor com consultas de múltiplas palavras.

3. Estudo de Caso: TF-IDF Acumulado vs. Similaridade de Cosseno

A tabela compara, para quatro consultas de exemplo, o documento vencedor segundo o TF-IDF acumulado (soma simples do TF-IDF de cada termo da consulta) e segundo a similaridade de cosseno do bônus (vetor completo no espaço de todo o vocabulário), com stopwords e stemming ativados.

Consulta	Vencedor	TF-IDF Acum.	Cosseno
irrigação soja	Doc 1	0.1784	0.2572
lagartas controle biológico	Doc 2	0.5169	0.6014
adubação nitrogênio milho	Doc 3	0.6898	0.6547
irrigação gotejamento	Doc 5	0.3608	0.4576

As duas métricas concordam sobre o vencedor nas quatro consultas, confirmando a corretude do cálculo: um termo raro no corpus (ex.: "nitrogênio", só no Doc 3) tem IDF alto e domina o ranking em ambas as fórmulas. A diferença está na escala: o TF-IDF acumulado cresce com o nº de termos da query e não tem limite superior fixo, enquanto o cosseno é normalizado pelo comprimento dos vetores e fica sempre entre 0 e 1, mais comparável entre consultas de tamanhos diferentes — o ganho esperado do bônus. Em "irrigação soja", como nenhum documento contém os dois termos, o Doc 1 vence por reunir maior peso combinado, enquanto Doc 2 e Doc 4 empatam por conterem só "soja".




Figura 1. Pontuação do documento vencedor em cada consulta: TF-IDF acumulado (soma simples) vs. similaridade de cosseno (vetor completo normalizado). O vencedor é o mesmo nas duas métricas; a diferença está na escala e na comparabilidade entre consultas.

4. Desenvolvimento e Divisão de Tarefas

Todas as etapas do projeto foram desenvolvidas individualmente por Pedro Nícollas Pereira Leon Lopes: definição e externalização do corpus agrícola (JSON), implementação do pipeline de pré-processamento, construção do índice invertido, cálculo de TF, IDF e TF-IDF acumulado do zero, implementação do bônus de similaridade de cosseno, construção do dashboard em Streamlit e redação deste relatório. A ferramenta de assistência por IA Claude Code (Anthropic) foi utilizada em partes pontuais, como auxílio na criação de visualizações e na revisão textual do relatório, cujo conteúdo foi verificado e validado integralmente pelo autor.

5. Conclusão

O protótipo demonstra como um índice invertido e o TF-IDF implementados do zero já produzem um ranqueamento coerente para consultas técnicas de um domínio especializado: termos raros no corpus (como "nitrogênio" ou "gotejamento") recebem IDF alto e dominam o ranking, enquanto termos comuns entre documentos (como "soja", presente em três dos cinco textos) têm peso menor por si só. O bônus de similaridade de cosseno preserva o mesmo vencedor em todas as consultas testadas e adiciona uma escala normalizada, mais adequada para comparar a confiança do sistema entre consultas de tamanhos distintos. A separação entre corpus, lógica de recuperação e interface deixa a solução pronta para crescer para uma base real de manuais técnicos da AgroTech Solutions.